

4.7 Application du TCL : intervalles de confiance

On considère une suite X_1, X_2, \dots, X_n de v.a.r indépendantes, suivant toutes une même loi de Bernoulli $\mathcal{B}(p)$ pour un paramètre inconnu $p \in]0, 1[$. On cherche à **estimer p à travers un échantillon** (x_1, \dots, x_n) de X_1, \dots, X_n ; un tel échantillon est une réalisation de X_1, \dots, X_n , c-à-d

$$(x_1, \dots, x_n) = (X_1(\omega), \dots, X_n(\omega))$$

pour un $\omega \in \Omega$.

Soit

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Pour n suffisamment grand (dans la pratique $n \geq 30$ suffit), on peut considérer, par le Théorème 6.2.3 que

$$Z := \frac{\bar{X} - p}{\sqrt{p(1-p)}/\sqrt{n}} = \sqrt{n} \frac{\bar{X} - p}{\sqrt{p(1-p)}} \sim \mathcal{N}(0, 1).$$

Soit $\alpha \in]0, 1[$ fixé ("**seuil de risque**"). On note z_α le nombre réel ≥ 0 tel que $\Pi(-z_\alpha) = \alpha$, c-à-d $\mathbf{P}(Z \geq z_\alpha) = \alpha$ ou bien $\mathbf{P}(Z \leq z_\alpha) = 1 - \alpha$. La valeur z_α est lue sur la table de la loi normale (voir table dans l'Annexe 8 plus loin). Alors

$$\mathbf{P}(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) = \Pi(z_{\alpha/2}) - \Pi(-z_{\alpha/2}) = 2\Pi(z_{\alpha/2}) - 1 = 1 - \alpha.$$

et donc

$$\begin{aligned} 1 - \alpha &= \mathbf{P}(-z_{\alpha/2} \leq Z \leq z_{\alpha/2}) \\ &= \mathbf{P}\left(-z_{\alpha/2} \leq \sqrt{n} \frac{\bar{X} - p}{\sqrt{p(1-p)}} \leq z_{\alpha/2}\right) \\ &= \mathbf{P}\left(\bar{X} - z_{\alpha/2} \frac{\sqrt{p(1-p)}}{\sqrt{n}} \leq p \leq \bar{X} + z_{\alpha/2} \frac{\sqrt{p(1-p)}}{\sqrt{n}}\right). \end{aligned}$$

Comme $\sqrt{p(1-p)} \leq 1/2$, on obtient

$$\mathbf{P}\left(\bar{X} - z_{\alpha/2} \frac{1}{2\sqrt{n}} \leq p \leq \bar{X} + z_{\alpha/2} \frac{1}{2\sqrt{n}}\right) \geq 1 - \alpha.$$

Posons $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, qui est la **moyenne observée** au vu de l'échantillon x_1, \dots, x_n . **L'intervalle de confiance**, au risque α , est alors donné par

$$I_\alpha = \left[\bar{x} - z_{\alpha/2} \frac{1}{2\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{1}{2\sqrt{n}} \right].$$

Ceci signifie que $p \in I_\alpha$ avec probabilité au moins $1 - \alpha$. Pour $\alpha = 0.05$, on a $z_{\alpha/2} = 1.96$ et donc $p \in \left[\bar{x} - 1.96 \frac{1}{2\sqrt{n}}, \bar{x} + 1.96 \frac{1}{2\sqrt{n}} \right]$ avec probabilité de 95%

Exemple 4.7.1 ((Sondage)) Au soir d'une élection, on veut estimer la proportion (inconnue) p des électeurs du candidat A dans l'ensemble de la population, à travers un sondage portant sur 2500 électeurs. Ici, $n = 2500$ est le nombre d'électeurs sondés (taille de l'échantillon du sondage) et, pour chaque $i \in \{1, \dots, 2500\}$, on a $X_i = 1$ si l'électeur i dit avoir voté pour A et $X_i = 0$ sinon.

Supposons que le sondage a révélé 1350 votes pour le candidat A. On a donc

$$\bar{x} = \frac{1350}{2500} = 0.54$$

et l'intervalle de confiance au risque $\alpha = 5\%$ est

$$[0.54 - 1.96 \times (1/2\sqrt{2500}), 0.54 + 1.96 \times (1/2\sqrt{2500})] = [0.52, 0.56];$$

on a donc une fourchette entre 52% et 56% dans la prédiction de votes pour le candidat A, avec probabilité de 95%.

Chapitre 5

Couples de variables aléatoires à densité

Nous avons étudié à la Section 3.3 des couples de variables aléatoires *discrets*. Dans ce chapitre, nous abordons les couples de variables aléatoires *continus*.

5.1 Vecteurs aléatoires à densité

Soit $(\Omega, \mathcal{F}, \mathbf{P})$ un espace probabilisé.

Soit $n \geq 1$. On rappelle qu'un *vecteur aléatoire* de dimension n est une application

$$Z: \Omega \rightarrow \mathbf{R}^n, \omega \mapsto (X_1(\omega), \dots, X_n(\omega)),$$

où X_1, \dots, X_n sont des v.a.r. On note en général Z par $Z = (X_1, \dots, X_n)$.

Dans le cas $n = 2$, on parlera de *couple aléatoire*, et on le notera souvent $Z = (X, Y)$.

On considère la tribu $\mathcal{B}(\mathbf{R}^n) \subset \mathcal{P}(\mathbf{R}^n)$ engendrée par les “rectangles” $I_1 \times I_2 \times \dots \times I_n$, où les I_i sont des intervalles de \mathbf{R} . Chaque partie de $\mathcal{B}(\mathbf{R}^n)$ est dite partie borélienne ou (borélien) de \mathbf{R}^n . On dit que $\mathcal{B}(\mathbf{R}^n)$ est la tribu des boréliens de \mathbf{R}^n .

Définition 5.1.1 (Loi et fonction de répartition d'un vecteur aléatoire) Soit $Z = (X_1, \dots, X_n)$ un vecteur aléatoire.

(i) La *loi* de Z (ou la *loi conjointe* de X_1, \dots, X_n) est la mesure de probabilité $P_Z: \mathcal{B}(\mathbf{R}^n) \rightarrow [0, 1]$ définie par

$$P_Z(I_1 \times I_2 \times \dots \times I_n) = \mathbf{P}(X_1 \in I_1, X_2 \in I_2, \dots, X_n \in I_n).$$

pour tous intervalles I_1, I_2, \dots, I_n de \mathbf{R} .

(ii) La *fonction de répartition* de Z est la fonction $F_Z : \mathbf{R}^n \rightarrow [0, 1]$ définie par

$$F_Z(x_1, x_2, \dots, x_n) = \mathbf{P}(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n).$$

Nous allons introduire maintenant les vecteurs aléatoires continus.

Définition 5.1.2 (Vecteur aléatoire à densité) Soit $Z = (X_1, \dots, X_n)$ un vecteur aléatoire. On dit que Z est une *vecteur aléatoire à densité* ou *vecteur aléatoire continue* si sa fonction de répartition F_Z s'écrit sous la forme

$$F_Z(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f(t_1, \dots, t_n) dt_1 \cdots dt_n \quad \text{pour tout } (x_1, \dots, x_n) \in \mathbf{R}^n$$

pour une fonction $f : \mathbf{R}^n \rightarrow \mathbf{R}$, appelée *densité de Z* , avec les propriétés suivantes :

1. $f(x_1, \dots, x_n) \geq 0$ pour tout $(x_1, \dots, x_n) \in \mathbf{R}^n$;
2. f est intégrable sur \mathbf{R}^n ;
3. $\int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(t_1, \dots, t_n) dt_1 \cdots dt_n = 1$.

Exemple 5.1.3 Soit $Z = (X, Y)$ de loi uniforme sur le triangle

$$T = \{(x, y) \in \mathbf{R}^2 \mid x \geq 0, y \geq 0, x + y \leq 1\};$$

comme l'aire de T est $1/2$, la densité de Z est $f = 2\mathbf{1}_T$, c-à-d

$$f(x, y) = \begin{cases} 2 & \text{si } (x, y) \in T \\ 0 & \text{si } (x, y) \notin T. \end{cases}$$

Remarque 5.1.4 Soit $Z = (X_1, \dots, X_n)$ un vecteur aléatoire à densité. On peut calculer ainsi la probabilité d'événements associés à Z au moyen de la densité f de Z :

$$\forall B \in \mathcal{B}(\mathbf{R}^n) \quad : \quad \mathbf{P}(Z \in B) = P_Z(B) = \int_B f(t_1, \dots, t_n) dt_1 \cdots dt_n.$$

5.2 Lois marginales

Dans toute la suite, on se limitera au cas $n = 2$, c-à-d à celui d'un couple aléatoire $Z = (X, Y) : \Omega \rightarrow \mathbf{R}^2$.

Les *lois marginales* du couple Z sont les lois P_X et P_Y de X et Y .

Proposition 5.2.1 Soit $Z = (X, Y)$ un vecteur aléatoire à densité f . Alors les v.a.r. X et Y sont continues, de densités f_X et f_Y données par

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy \quad \text{et} \quad f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$$

pour $x, y \in \mathbf{R}$.

Démonstration Soit $x \in \mathbf{R}$. On a $\{X \leq x\} = \{X \leq x, Y \in \mathbf{R}\}$. Il s'ensuit que, pour la fonction de répartition F_X de X , on a

$$\begin{aligned} F_X(x) &= \mathbf{P}(X \leq x) = \mathbf{P}(X \leq x, Y \in]-\infty, +\infty[) \\ &= \mathbf{P}_Z([-\infty, x] \times]-\infty, +\infty[) = \int_{-\infty}^x \int_{-\infty}^{+\infty} f(t, y) dy \\ &= \int_{-\infty}^x f_X(t) dt, \end{aligned}$$

où $f_X(t) = \int_{-\infty}^{+\infty} f(t, y) dy$. Ceci montre que X est continue à densité f_X .

De manière similaire, on montre que Y est continue à densité f_Y . ■

Exemple 5.2.2 Reprenons l'Exemple 5.1.3. On rappelle que la densité de $Z = (X, Y)$ est $f = 2\mathbf{1}_T$, où T est le triangle $\{(x, y) \in \mathbf{R}^2 \mid x \geq 0, y \geq 0, x + y \leq 1\}$.

La loi marginale f_X de X est donnée par $f_X(x) = 0$ pour $x \notin [0, 1]$ et

$$f_X(x) = 2 \int_0^{1-x} \mathbf{1}_T(x, y) dx dy = 2(1-x)$$

pour $x \in [0, 1]$. De manière similaire, $f_Y(y) = 0$ pour $y \notin [0, 1]$ et $f_Y(y) = 2(1-y)$ pour $y \in [0, 1]$.

On rappelle que les v.a.r. X et Y sont indépendantes si et seulement si

$$\forall (x, y) \in \mathbf{R}^2 : \quad \mathbf{P}(X \leq x, Y \leq y) = \mathbf{P}(X \leq x) \mathbf{P}(Y \leq y).$$

Proposition 5.2.3 Soit $Z = (X, Y)$ un vecteur aléatoire à densité f . Les deux propriétés suivantes sont équivalentes :

- (i) X et Y sont indépendantes;
- (ii) $f(x, y) = f_X(x)f_Y(y)$ pour tout $(x, y) \in \mathbf{R}^2$.

Démonstration Par définition, X et Y sont indépendantes si et seulement si $F_Z(x, y) = F_X(x)F_Y(y)$, c-à-d si et seulement si

$$(*) \int_{-\infty}^x \int_{-\infty}^y f(t, s) dt ds = \left(\int_{-\infty}^x f_X(t) dt \right) \left(\int_{-\infty}^y f_Y(s) ds \right)$$

pour tout $(x, y) \in \mathbf{R}^2$.

Supposons que $f(x, y) = f_X(x)f_Y(y)$ pour tout $(x, y) \in \mathbf{R}^2$; alors la relation (*) est satisfaite et X et Y sont donc indépendantes.

Réciproquement, supposons que X et Y sont indépendantes et que donc la relation (*) est satisfaite. Alors, on a

$$\int_{-\infty}^x \int_{-\infty}^y f(t, s) dt ds = \int_{-\infty}^x \int_{-\infty}^y (f_X(t)f_Y(s)) dt ds$$

pour tout $(x, y) \in \mathbf{R}^2$. Par identification, on a $f(x, y) = f_X(x)f_Y(y)$ pour tout $(x, y) \in \mathbf{R}^2$. ■

On peut démontrer une formule de transfert analogue à celle pour un couple de v.a.r. discrètes.

Proposition 5.2.4 (Formule de transfert) Soit $Z = (X, Y)$ un vecteur aléatoire à densité f . Soit $g : \mathbf{R}^2 \rightarrow \mathbf{R}$ une fonction continue (ou plus généralement, mesurable). On suppose que l'intégrale $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} |g(x, y)| f(x, y) dx dy$ est finie. Alors la v.a.r. $g(X, Y)$ possède une espérance et on a

$$\mathbb{E}(g(X, Y)) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$$

Démonstration Omise.

5.3 Covariance

Comme pour un couple de v.a.r. discrètes, on peut définir la covariance d'un couple de variables continues.

Définition 5.3.1 (Covariance d'un couple aléatoire à densité) Soit $Z = (X, Y)$ un vecteur aléatoire à densité. On suppose que X et Y possèdent des variances. La *covariance* de Z (ou de X et Y), notée $\text{Cov}(X, Y)$, est le nombre

$$\text{Cov}(X, Y) := \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

Les v.a.r. X et Y sont dites *non corrélées* si $\text{Cov}(X, Y) = 0$.

La covariance a des propriétés similaires à celle pour un couple de v.a.r. discrètes.

Proposition 5.3.2 Soit $Z = (X, Y)$ un vecteur aléatoire à densité f . On suppose que X et Y possèdent une variance.

(i) (**Formule de Koenig-Huygens**) On a

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y).$$

(ii) On a

$$\text{Cov}(X, Y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyf(x, y)dx dy - \left(\int_{-\infty}^{+\infty} xf_X(x)dx \right) \left(\int_{-\infty}^{+\infty} yf_Y(y)dy \right).$$

(iii) Si X et Y sont indépendantes, alors $\text{Cov}(X, Y) = 0$; la réciproque est fausse en général.

Démonstration

(i) On a, en développant et en utilisant la linéarité de l'espérance

$$\begin{aligned} \text{Cov}(X, Y) &= \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) = \mathbb{E}(XY - X\mathbb{E}(Y) - \mathbb{E}(X)Y + \mathbb{E}(X)\mathbb{E}(Y)) \\ &= \mathbb{E}(XY) - \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(X)\mathbb{E}(Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y). \end{aligned}$$

(ii) Par la formule de transfert (Proposition 5.2.4), on a

$$\mathbb{E}(XY) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyf(x, y)dx dy.$$

ceci montre que (ii) est une conséquence de (i) .

(iii) Supposons que X et Y sont indépendantes. Alors, en utilisant la Proposition 5.2.3, on a

$$\begin{aligned}\mathbb{E}(XY) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyf(x, y)dx dy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyf_X(x)f_Y(y)dx dy \\ &= \left(\int_{-\infty}^{+\infty} xf_X(x)dx \right) \left(\int_{-\infty}^{+\infty} yf_Y(y)dy \right) \\ &= \mathbb{E}(X)\mathbb{E}(Y),\end{aligned}$$

c-à-d $\text{Cov}(X, Y) = 0$. ■

Exemple 5.3.3 Reprenons l'Exemple 5.1.3 et 5.2.2 On rappelle que la loi f de $Z = (X, Y)$ est la loi uniforme sur le triangle T ; les lois marginales f_X et f_Y sont données par $f_X(x) = f_Y(x) = 2\mathbf{1}_{[0,1]}(x)(1-x)$. On calcule que

$$\mathbb{E}(X) = \mathbb{E}(Y) = 2 \int_0^1 x(1-x)dx = 1/3$$

et que

$$\mathbb{E}(XY) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyf(x, y)dx dy = 2 \int_0^1 \int_0^{1-x} xy dx dy = \int_0^1 x(1-x)^2 dx = 1/12$$

D'où $\text{Cov}(X, Y) = (1/3)^2 - 1/12 = -1/36$.